

Análisis de Clustering para la Segmentación de Canciones en Spotify

Alberto E. Marichal Fonseca

Junio 2025

Resumen

Este informe detalla el proceso de análisis de un conjunto de datos de canciones de Spotify con el objetivo de segmentar y entender los factores que contribuyen a su popularidad. Ante la falta de una métrica de popularidad unificada y las limitaciones en la recolección de datos, el enfoque del proyecto transitó de un modelo supervisado a uno no supervisado. Se exploraron y compararon dos algoritmos de clustering, K-Means y Modelos de Mezcla Gaussiana (GMM). El análisis demuestra que GMM ofrece una segmentación más flexible y significativa para este tipo de datos, a pesar de las métricas de separación geométrica. La selección del número óptimo de clústeres se validó utilizando el Criterio de Información Bayesiano (BIC) y otras métricas de calidad como Calinski-Harabasz y Davies-Bouldin, concluyendo que los clústeres generados, aunque solapados, son interpretables y de gran utilidad analítica.

1. Definición del Problema y Características

El objetivo principal de este proyecto es predecir o segmentar la popularidad de las canciones basándose en un conjunto de características. La popularidad es un concepto multifactorial que puede ser influenciado por propiedades intrínsecas del audio, metadatos de la canción y la fama del artista.

Las características consideradas para este análisis son:

1.1. Características de audio y musicales

- **Bailabilidad (Danceability):** Medida de qué tan adecuada es una canción para bailar
- **Energía (Energy):** Intensidad y actividad percibida
- **Tonalidad (Key):** Nota principal de la canción
- **Modalidad (Mode):** Mayor (1) o menor (0)
- **Volumen (Loudness):** Intensidad general en decibelios
- **Verbocidad (Speechiness):** Presencia de palabras habladas
- **Acústica (Acousticness):** Medida de acústica no eléctrica
- **Instrumentalidad (Instrumentalness):** Predominio instrumental
- **Viveza (Liveness):** Presencia de audiencia en la grabación
- **Valencia (Valence):** Positividad musical
- **Tempo:** Velocidad en BPM
- **Duración (Duration):** Longitud en milisegundos

1.2. Métricas de rendimiento en plataforma

- **Rank:** Posición en el ranking
- **Peak Rank:** Mejor posición alcanzada
- **Previous Rank:** Posición previa

- **Weeks on Chart:** Semanas en listado
- **Streams:** Número de reproducciones

1.3. Metadatos de la canción y álbum

- **Release Date:** Fecha de lanzamiento
- **Album Num Tracks:** Canciones en el álbum
- **Album Cover:** Imagen del álbum
- **Source:** Fuente de los datos

1.4. Características del artista

- **Artist Names:** Nombre(s) del artista(s)
- **Artists Num:** Número de artistas
- **Artist Individual:** Si es artista individual
- **Artist ID:** Identificador único
- **Artist Genre:** Género musical principal
- **Artist Img:** Imagen del artista
- **Collab:** Si es colaboración

1.5. Contexto geográfico y lingüístico

- **Country:** País de origen
- **Region:** Región geográfica
- **Language:** Idioma principal

2. Datos y Preprocesamiento

2.1. Fuentes de Datos y Desafíos

Se utilizaron múltiples fuentes de datos, incluyendo datasets de Spotify y scraping de la web kworkb.net para obtener datos de streams de marzo de 2023. Los principales desafíos fueron:

- **Limitaciones de API:** La API de Spotify impone límites de solicitudes, lo que hizo inviable la recolección masiva de datos para las canciones del dataset.
- **Datos Faltantes:** como se tenían bastante cantidad de datos los valores faltantes se eliminó sus filas correspondientes.

3. Metodología de Clustering

Debido a las dificultades para obtener una variable objetivo de popularidad consistente y unificada, se adoptó un **enfoque no supervisado**. El objetivo pasó de predecir la popularidad a segmentar las canciones en grupos homogéneos y significativos basados en sus características.

3.1. Enfoque Inicial: K-Means

El primer algoritmo considerado fue K-Means, un método de clustering "duro" que asigna cada canción a un único clúster. Es un buen punto de partida, pero su suposición de que los clústeres son esféricos y de tamaño similar es muy estricta para datos complejos como los musicales.

3.2. Selección del Número de Clústeres

Para determinar el número óptimo de clústeres para el Kmeans, se utilizó el metodo del codo




Figura 1: Visualización de los k candidatos




Figura 2: Visualización de los clústeres generados por KMeans(k=3), mostrando su forma y separación.

- calinski harabasz score: 5003.060091342737
- davies bouldin score 2.616709749092157
- silhouette score:0.09793327470088771




Figura 3: Visualización de los clústeres generados por KMeans($k=4$), mostrando su forma y separación.

- calinski harabasz score: 4573.827866111025
- davies bouldin score 2.4850030758118082
- silhouette score 0.0925154329480957

3.3. Enfoque Mejorado: Modelos de Mezcla Gaussiana (GMM)

Para superar las limitaciones de K-Means, se optó por un Modelo de Mezcla Gaussiana (GMM). GMM es un modelo probabilístico que asume que los datos provienen de una mezcla de varias distribuciones gaussianas. Sus ventajas clave son:

- **Clustering "Suave":** Asigna una probabilidad de pertenencia a cada clúster, lo que es ideal para canciones que se encuentran en la frontera de varios géneros o estilos.
- **Flexibilidad de Forma:** Puede modelar clústeres elipsoidales y de diferentes tamaños, adaptándose mejor a la estructura real de los datos.

4. Resultados y Análisis del Clustering GMM

4.1. Selección del Número de Clústeres (BIC)

Para determinar el número óptimo de clústeres para el GMM, se utilizó el Criterio de Información Bayesiano (BIC). El BIC equilibra el ajuste del modelo con su complejidad, penalizando los modelos con más parámetros. Se busca el codo,^{en} el gráfico, que representa el punto donde añadir más clústeres ya no proporciona una mejora sustancial.

4.2. Evaluación de la Calidad del Clustering

La evaluación de los clústeres reveló una visión interesante sobre la naturaleza de los datos.




Figura 4: El score BIC decrece significativamente hasta $k=4$, punto a partir del cual la curva se aplanada, sugiriendo que 5 es el número óptimo de componentes.




Figura 5: GMM con $k=5$

- **Silhouette Score:** Esta métrica arrojó un valor muy bajo (aprox. 0.103112198713655), lo cual es esperado. El Silhouette Score mide la separación geométrica y penaliza duramente los clústeres que se solapan. Un valor bajo aquí no indica un mal clustering, sino que confirma que los segmentos de canciones no son "islas" separadas, sino "nubes" que se mezclan entre sí.
- **Métricas Alternativas:** Se utilizaron métricas más adecuadas para clústeres solapados:




Figura 6: GMM con $k=3$.

- **Índice Calinski-Harabasz:** Arrojó un valor de **3129.83688005196**. Un valor más alto es mejor, y este resultado, al ser el pico en las pruebas, apoya la contrario a lo que sugería el BIC de $k=3$.
- **Índice Davies-Bouldin:** Se obtuvo un valor de **3.445982427823916**. Un valor más bajo es mejor, y este fue el mínimo encontrado con $k=3$.