

PREDICCIÓN DE LA POPULARIDAD DE CANCIONES EN SPOTIFY



28 DE AGOSTO DE 2025

ALBERTO E MARICHAL FONSECA

Universidad de la Habana

Para predecir la popularidad, se utilizó un dataset con datos internos de las canciones y además de atributos del autor y del año de cada canción. Este contaba con 172230 ejemplos no nulos y 72 características.

Datos:

Canción:

Acousticness: (Double)

Danceability: (Double)

Duration_ms: (Double) duración en milisegundos

Energy: (Double)

Explicit: (Double)

Instrumentalness: (Double)

Liveness: (Double)

Loudness: (Double)

Popularity: (Int) variable a predecir [0,100]

Speechiness: (Double)

Tempo: (Double)

Valence: (Double)

Year: (Date)

Key: (Int)

Minor: (Int)


Major: (Int)

Mode: (int)

Autor: Se tienen las mismas características que la canción pero del autor, además la popularidad del autor.

Año: Se tienen las mismas características que la canción pero del autor, además la popularidad del año.

Al analizar la correlación de las variables, se observa que:



Existe una moderada correlación entre las variables (algunas inversas otras directa) incluyendo la popularidad, también la característica mode es constante (la cual no se tuvo en cuenta).


Para realizar la predicción se siguieron dos enfoques principales “Clasificación” y “Regresión”.

Clasificación:


Como la variable objetivo era un entero en $[0,100]$ para llevar el problema a clasificación se definió los siguientes rangos:

3 clases 0-20 baja, 21-45 media y 46-100 alta.

4 clases: 0 como no popular, 1-20 baja, 21-40 media y 41-100 alta popularidad.



Dado que eran 72 características, y algunas están correlacionadas se uso PCA para reducir la dimensión a 2 características y a las características que explicaran el 85% de la varianza y selección de características para diferentes valores de k=10,20,30.



Resultados 4 clases:


modelos	F1-macro train	F1-macro test	F1-weighted train	F1-weighted test
XGBoost	0.82	0.80	0.82	0.79
Random forest	0.86	0.81	0.85	0.80
HistogramGradientBoosting	0.80	0.79	0.79	0.78
ExtraTree	0.85	0.81	0.85	0.80
KNN	0.82	0.79	0.82	0.70
LogisticRegression (ovo)	0.74	0.74	0.74	0.74
LogisticRegression (ovr)	0.70	0.70	0.71	0.70
DecisionTree	0.86	0.81	0.85	0.80
SVM (kernel rbf) k=6	0.76	0.76	0.76	0.76

Resultados 3 clases:

modelos	F1-macro train	F1-macro test	F1-weighted train	F1-weighted test
XGBoost	0.86	0.83	0.87	0.85
Random forest	1.0	0.83	1.0	0.85
HistogramGradientBoosting	0.86	0.83	0.87	0.85
ExtraTree	0.93	0.82	0.94	0.84
KNN	0.82	0.78	0.84	0.80
DecisionTree	0.84	0.82	0.85	0.84
SVC (kernel rbf) k=10	0.81	0.81	0.83	0.83

XGBoost, ExtraTree y Random forest para k=30,20 dieron resultados de un claro overfitting (3 clases), el entramieto muy buenos; pero en el conjunto de pruebas muy bajos comparados al entrenamiento. Sin embargo con el PCA con n=2 y 85% los resultados son apenas mejor que decir clases aleatorias.

Dado el sesgo de la distribución de la popularidad hacia 0 lo cual es natural, hay muchas más canciones con baja popularidad; intentar modelarlo como clasificación siempre va a incluir ese sesgo en las clases, incluso si se divide por cuantiles, los modelos no eran capaces de distinguir correctamente las clases de media y alta, sin embargo las bajas las hacian bien.




Regresión:

Para modelar el problema como regresión, se tuvo un problema, era que el valor a predecir es un entero y los modelos de regresión, devuelven valores reales. Para

solucionar esto, pues se transformó a un problema continuo equivalente y luego se volvió al original. Se aplicó logaritmo (y dividir entre 100) a la popularidad para llevarlo a continuo y luego exponencial (multiplicar por 100) y redondeo para volver a la escala. También se aplicó una reducción de dimensionalidad con el metodo recursivo y con el selección de características para regresión.


Dado que no habia relación lineal de ninguna de las características con la popularidad, se utilizaron modelos de arboles, svm con kernel rbf y modelos basados en distancias.



relaciones de la popularidad, ultima fila.

Resultados:

modelos	MAE	MSE	RMSE	R^2
XGBoost	4.79	64.34	8.02	0.86
Random forest	4.76	64.0	8.0	0.86
Lightgbm (0,1)	4.95	60.37	7.77	0.87
KNN (0-1)	5.89	78.98	8.88	0.83
SVC (kernel rbf) k=10	5.64	83.79	9.15	0.82



Lightgbm

El modelo que obtuvo mejores métricas fue el lightgbm aunque tiene ligeramente mayor error absoluto (MAE) que XGBoost y Random Forest, tiene un mejor RMSE que penaliza los errores grandes, ya que errores pequeños no eran de gran valor porque equivocarse por 1-2-3 valores no es muy grave, pero si lo es equivocarse por 30-50+ y también logró explicar en un 87% la variabilidad de los datos.

